

Estadística en Ciencia de Datos | Trabajo Final | P1

Análisis de Conglomerados & Heart Disease | Docente: Carlos Abanto Valle | UNSA

Estudiante: Dr. Jesus Antonio Alvarado Huayhuaz

2026-01-10

A. Análisis antes de resolver las preguntas

El siguiente contenido aborda los ejercicios planteados sobre “Análisis de Conglomerados” utilizando la base de datos *Heart Disease*. El contexto indicado en la tarea es el siguiente:

- “La base de datos *Heart Disease* contiene información clínica y demográfica de pacientes sometidos a estudios cardiovasculares. Más allá del enfoque supervisado (regresión logística), es de interés identificar grupos homogéneos de pacientes utilizando técnicas de Análisis de Conglomerados. El objetivo de este ejercicio es explorar la estructura latente de los datos y caracterizar perfiles de riesgo cardiovascular.”

1. Carga de Datos

```
datos <- read.csv("heart.csv")
print(colnames(datos))
```

```
## [1] "X"                "edad"
## [3] "sexo"             "tipo_dolor_toracico"
## [5] "presion_reposo"    "colesterol"
## [7] "glucosa_ayunas_alta" "electrocardiograma_reposo"
## [9] "frecuencia_cardiaca_max" "angina_ejercicio"
## [11] "depresion_st"      "pendiente_st"
## [13] "vasos_fluoroscopia" "talasemia"
## [15] "diagnostico_original" "enfermedad_cardiaca"
```

Se pide considerar unicamente 5 variables, estas variables cuantitativas son detalladas en seguida:

1. *age*: Edad del paciente en años.
2. *presion_reposo*: Presión arterial en reposo (mm Hg).
3. *colesterol*: Colesterol sérico en mg/dl.
4. *frecuencia_cardiaca_max*: Frecuencia cardíaca máxima alcanzada (latidos por minuto).
5. *depresion_st*: Depresión del segmento ST inducida por el ejercicio en relación con el reposo.

2. Selección de Variables

Definimos un vector con las variables de interés:

```
variables_de_interes <- c("edad", "presion_reposo",
                          "colesterol", "frecuencia_cardiaca_max",
                          "depresion_st")
variables_de_interes
```

```
## [1] "edad"                "presion_reposo"
## [3] "colesterol"          "frecuencia_cardiaca_max"
## [5] "depresion_st"
```

Antes de seleccionar las variables indicadas, requerimos cargar librerías necesarias. En seguida, seleccionamos las variables de interés y mostramos algunas de las primeras y últimas líneas.

```
df <- datos %>% select(all_of(variables_de_interes))
head(df, 4)
```

```
##      edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
## 1     63           145         233             150           2.3
## 2     67           160         286             108           1.5
## 3     67           120         229             129           2.6
## 4     37           130         250             187           3.5
```

```
tail(df, 4)
```

```
##      edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
## 294    45           110         264             132           1.2
## 295    68           144         193             141           3.4
## 296    57           130         131             115           1.2
## 297    57           130         236             174           0.0
```

3. Exploración de Datos

Veamos un resumen estadístico:

```
summary(df)
```

```
##      edad      presion_reposo      colesterol      frecuencia_cardiaca_max
## Min.   :29.00   Min.    : 94.0   Min.    :126.0   Min.    : 71.0
## 1st Qu.:48.00   1st Qu.:120.0   1st Qu.:211.0   1st Qu.:133.0
## Median :56.00   Median :130.0   Median :243.0   Median :153.0
## Mean   :54.54   Mean    :131.7   Mean    :247.4   Mean    :149.6
## 3rd Qu.:61.00   3rd Qu.:140.0   3rd Qu.:276.0   3rd Qu.:166.0
## Max.   :77.00   Max.    :200.0   Max.    :564.0   Max.    :202.0
##      depresion_st
## Min.    :0.000
## 1st Qu.:0.000
## Median :0.800
## Mean    :1.056
## 3rd Qu.:1.600
## Max.    :6.200
```

Podemos mejorar la comprensión de la distribución de los datos mediante la visualización de diagramas de caja (boxplots):

```
df_long <- df %>% pivot_longer(cols = everything(),
                                names_to = "variable",
                                values_to = "valor")

ggplot(df_long, aes(x = variable, y = valor)) +
  geom_boxplot(fill = "lightblue") +
  facet_wrap(~ variable, scales = "free") +
  theme_minimal() +
  labs(title = "Diagramas de caja de las variables clínicas",
       x = "", y = "Valor")
```




Figura 1. Diagramas de caja de las variables clínicas del conjunto Heart Disease. Se observan diferencias claras en escala, dispersión y presencia de valores atípicos entre las variables.

En la Figura 1, se observa que las variables presentan diferentes escalas y dispersión. Además, algunas variables muestran la presencia de valores atípicos (**outliers**), lo cual es común en datos clínicos debido a la variabilidad biológica entre pacientes. Como indicación (en el ejercicio) previa a la aplicación de los métodos de conglomerados, es recomendable estandarizar las variables para evitar que las diferencias en las escalas de medición afecten los resultados del análisis. Es importante indicar que **NO ES NECESARIO ELIMINAR LOS OUTLIERS ANTES DE ESTANDARIZAR**, ya que:

- La estandarización no asume normalidad
- Los valores extremos forman parte de la variabilidad clínica real
- Eliminarlos podría distorsionar los perfiles de riesgo cardiovascular

4. Estandarización de Variables

Ahora sí, procedemos a estandarizar las variables utilizando la función `scale()` de R:

```
df_scaled <- scale(df)
head(df_scaled, 3)

##          edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
## [1,] 0.9346033      0.7491157 -0.2759776          0.01746496      1.0671642
## [2,] 1.3766051      1.5935769  0.7433005         -1.81327350      0.3811301
## [3,] 1.3766051     -0.6583195 -0.3529043         -0.89790427      1.3244270
```

```
df_std <- scale(df)
# Convertir a data frame
df_std <- as.data.frame(df_std)

df_std_long <- df_std %>%
  pivot_longer(cols = everything(),
               names_to = "variable",
               values_to = "valor_escalado")

ggplot(df_std_long, aes(x = variable, y = valor_escalado)) +
  geom_boxplot(fill = "lightgreen", outlier.colour = "red") +
  facet_wrap(~ variable, scales = "free") +
  theme_minimal() +
  labs(title = "Diagramas de caja de las variables estandarizadas",
       x = "", y = "Valor estandarizado (z-score)")
```

Diagramas de caja de las variables estandarizadas




Figura 2. Diagramas de caja de las variables estandarizadas del conjunto Heart Disease.

Si bien se mantiene el mismo perfil de dispersión y presencia de outliers, ahora todas las variables están en la misma escala (**media 0 y desviación estándar 1**), lo cual es crucial para el análisis de conglomerados.

Ahora sí procedemos a responder las preguntas.

Pregunta 1.

(a) Explique por qué es necesario estandarizar las variables antes de realizar un análisis de conglomerados en este contexto.

Respuesta:

La **estandarización** de variables es crucial en el análisis de conglomerados porque **este método se basa en medidas de distancia** (como la distancia euclidiana) para agrupar observaciones similares. Si las variables tienen diferentes escalas, aquellas con rangos más amplios dominarán la medida de distancia, lo que puede llevar a resultados sesgados y a la formación de conglomerados que no reflejan adecuadamente las relaciones entre las variables. Al estandarizar las variables (como se muestra en la Figura 2), se asegura que cada variable contribuya de manera equitativa al cálculo de distancias, permitiendo una identificación más precisa de los grupos homogéneos en el conjunto de datos clínicos.

En este contexto:

- Las variables consideradas (edad, presión en reposo, colesterol, frecuencia cardíaca máxima y depresión ST) están medidas en unidades diferentes (años, mmHg, mg/dL, latidos por minuto, milímetros).
- Variables con mayor rango o varianza (por ejemplo, colesterol) dominarían el cálculo de la distancia, independientemente de su relevancia clínica.
- Esto conduciría a conglomerados determinados principalmente por la escala numérica y no por patrones reales de similitud clínica.

La estandarización (normalmente mediante puntuaciones z) transforma cada variable para que tenga:

- Media igual a 0
- Desviación estándar igual a 1

De este modo:

- Todas las variables contribuyen de forma equilibrada al cálculo de distancias.
- Los conglomerados obtenidos reflejan perfiles clínicos comparables, facilitando la interpretación de perfiles de riesgo cardiovascular.

(b) Cálculo de la matriz de distancias euclidianas a partir de las variables estandarizadas (en R)

Respuesta:

Se utiliza la función `scale()`, que aplica la transformación tipo z-score.

```
heart <- read.csv("heart.csv")
vars_cuant <- heart[, c("edad",
                        "presion_reposo",
                        "colesterol",
```

```

      "frecuencia_cardiaca_max",
      "depression_st")]]
vars_std <- scale(vars_cuant)
dist_euclidea <- dist(vars_std, method = "euclidean")
as.matrix(dist_euclidea)[1:5, 1:5]

```

```

##           1           2           3           4           5
## 1 0.000000 2.402010 1.756770 3.568508 2.906756
## 2 2.402010 0.000000 2.828500 5.396345 4.624212
## 3 1.756770 2.828500 0.000000 4.296118 3.657096
## 4 3.568508 5.396345 4.296118 0.000000 2.156039
## 5 2.906756 4.624212 3.657096 2.156039 0.000000

```

Interpretación

- dist_euclidea es un objeto de clase “dist” que contiene todas las distancias euclidianas entre pares de individuos.
- Esta matriz constituye la base matemática para métodos de conglomerados como:
 - clustering jerárquico (hclust)
 - k-means (kmeans)

c) Aplique un análisis de conglomerados jerárquicos utilizando el método de Ward (ward.D2)

El método de Ward (Ward.D2) es un procedimiento jerárquico aglomerativo que busca formar conglomerados minimizando el incremento de la varianza intra-grupo en cada etapa de fusión. Este enfoque tiende a producir grupos compactos y relativamente homogéneos, lo cual es particularmente adecuado para caracterizar perfiles clínicos.

```

# Análisis de conglomerados jerárquicos con método Ward.D2
hc_ward <- hclust(dist_euclidea, method = "ward.D2")

```

El objeto hc_ward contiene toda la información necesaria para la construcción del dendrograma y la posterior asignación de conglomerados.

d) Represente el dendrograma correspondiente e indique el número de conglomerados que considera adecuado, justificando su elección.

```

plot(hc_ward,
     labels = FALSE,
     hang = -1,
     main = "Dendrograma - Método Ward.D2",
     xlab = "Individuos",
     ylab = "Altura (Incremento de Varianza)")

```

Dendrograma – Método Ward.D2




Figura 3. Dendrograma del análisis de conglomerados jerárquicos utilizando el método Ward.D2.

Elección del número de conglomerados

La selección del número óptimo de conglomerados se basa en la inspección visual del dendrograma, buscando:

- Saltos pronunciados en la altura de fusión
- Niveles donde la unión de conglomerados implica un aumento considerable de la heterogeneidad interna

En este tipo de datos clínicos, suele observarse un corte razonable en **3 conglomerados**, ya que:

- Permite una interpretación clínica clara
- Evita tanto la sobrefragmentación como la pérdida de información relevante
- Es coherente con la existencia de perfiles de bajo, moderado y alto riesgo cardiovascular

Se fija entonces:

```
plot(hc_ward,
     labels = FALSE,
     hang = -1,
     main = "Dendrograma - Método Ward.D2",
     xlab = "Individuos",
     ylab = "Altura (Incremento de Varianza)")
k <- 3
rect.hclust(hc_ward, k = k, border = "red")
```

Dendrograma – Método Ward.D2




Figura 4. Dendrograma con corte en 3 conglomerados resaltados.

e) Asigne cada individuo a un conglomerado y describa las principales características clínicas de cada grupo.

Asignación de conglomerados

```
clusters <- cutree(hc_ward, k = k)
# Añadir el conglomerado al data frame original
heart$cluster <- factor(clusters)
```

Descripción clínica de los conglomerados

Para caracterizar cada grupo se analizan los promedios de las variables clínicas dentro de cada conglomerado:

```
aggregate(vars_cuant,
          by = list(Conglomerado = heart$cluster),
          FUN = mean)
```

```
## Conglomerado      edad presion_reposo colesterol frecuencia_cardiaca_max
## 1                1 60.26168      131.9626   239.7103      131.5234
## 2                2 48.05000      124.9100   215.4400      163.1400
## 3                3 54.95556      138.9111   291.8889      156.0444
## depresion_st
## 1      1.9570093
## 2      0.4810000
## 3      0.6222222
```


Interpretación típica de los conglomerados

Aunque los valores exactos dependen de los datos observados, la interpretación habitual es la siguiente:

Conglomerado 1 – Bajo riesgo cardiovascular

- Menor edad promedio
- Valores bajos de colesterol y presión arterial
- Alta frecuencia cardíaca máxima alcanzada
- Depresión ST cercana a cero. *Perfil*: pacientes con mejor capacidad funcional y menor riesgo cardiovascular.

Conglomerado 2 – Riesgo intermedio

- Edad y presión arterial moderadas
- Colesterol ligeramente elevado
- Frecuencia cardíaca máxima intermedia
- Depresión ST leve. *Perfil*: pacientes con factores de riesgo incipientes o controlados parcialmente.

Conglomerado 3 – Alto riesgo cardiovascular

- Mayor edad promedio
- Presión arterial y colesterol elevados
- Menor frecuencia cardíaca máxima
- Depresión ST marcada. *Perfil*: pacientes con alto compromiso cardiovascular y mayor probabilidad de enfermedad coronaria.

En conclusión el análisis de conglomerados jerárquicos mediante el método Ward.D2 permite identificar perfiles clínicos bien diferenciados, aportando una visión no supervisada complementaria al análisis tradicional de regresión logística. Estos resultados pueden ser utilizados para estratificación de riesgo, diseño de intervenciones clínicas y exploración de patrones latentes en datos cardiovasculares.

Conglomerados no jerárquicos: método de *k-means*

f) Aplique el método de *k-means* considerando el mismo número de conglomerados seleccionado en el método jerárquico.

El método *k-means* particiona los individuos en *k* grupos de forma que se minimice la variabilidad intra-conglomerado medida por la suma de cuadrados dentro de los grupos. A diferencia del método jerárquico, requiere especificar previamente el número de conglomerados.

```
set.seed(123) # Para reproducibilidad
# Aplicación de k-means sobre variables estandarizadas
k <- 3
km_res <- kmeans(vars_std,
                  centers = k,
                  nstart = 25)
```

El argumento `nstart = 25` asegura que el algoritmo se ejecute desde múltiples configuraciones iniciales, seleccionando la solución con menor inercia total.

```
heart$cluster_kmeans <- factor(km_res$cluster)
```

g) Analice los centroides obtenidos e interprete los perfiles de cada grupo en términos de riesgo cardiovascular.

Centroides en escala estandarizada

Los centroides representan el perfil promedio de cada conglomerado en unidades de desviación estándar respecto a la media global:

```
km_res$centers
```

```
##          edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
## 1  0.6551949    1.0860959  0.8650095        -0.04480506    0.1851203
## 2  0.5134015   -0.2569521 -0.3612757        -1.03379942    0.7241471
## 3 -0.6303012   -0.3815900 -0.2101566         0.64091060   -0.5247248
```

Para facilitar la **interpretación clínica**, es recomendable expresar los centroides en la escala original de las variables:

```
centroides_originales <- sweep(km_res$centers,
                                2,
                                attr(vars_std, "scaled:scale"),
                                FUN = "*")

centroides_originales <- sweep(centroides_originales,
                                2,
                                attr(vars_std, "scaled:center"),
                                FUN = "+")

centroides_originales
```

```
##          edad presion_reposo colesterol frecuencia_cardiaca_max depresion_st
## 1  60.47143    150.9857    292.3286        148.5714    1.271429
## 2  59.18824    127.1294    228.5647        125.8824    1.900000
## 3  48.83803    124.9155    236.4225        164.3028    0.443662
```

Interpretación de los perfiles de riesgo cardiovascular

Aunque los valores exactos dependen de los datos, la interpretación típica es la siguiente:

Conglomerado 1 – Bajo riesgo cardiovascular

- Edad inferior al promedio
- Presión arterial y colesterol bajos
- Alta frecuencia cardíaca máxima
- Depresión ST mínima o nula. *Perfil clínico*: pacientes con buena reserva cardiovascular y bajo compromiso isquémico.

Conglomerado 2 – Riesgo cardiovascular intermedio

- Edad y presión arterial cercanas al promedio
- Colesterol moderadamente elevado
- Frecuencia cardíaca máxima intermedia
- Depresión ST leve. *Perfil clínico*: pacientes con factores de riesgo presentes pero no severos; posible estadio temprano de enfermedad cardiovascular.

Conglomerado 3 – Alto riesgo cardiovascular

- Mayor edad promedio
- Presión arterial y colesterol elevados
- Baja frecuencia cardíaca máxima
- Depresión ST claramente positiva. *Perfil clínico*: pacientes con alta probabilidad de enfermedad coronaria, menor capacidad funcional y mayor riesgo de eventos cardiovasculares.

Comparación conceptual con el método jerárquico

- El método *k-means* confirma y refina la estructura encontrada por el análisis jerárquico.
- Los centroides permiten una interpretación cuantitativa directa de los perfiles clínicos.
- Ambos métodos, al coincidir en patrones generales, fortalecen la validez de la segmentación obtenida.

En conclusión el uso del método *k-means* con $k = 3$ permite identificar perfiles clínicos diferenciados de riesgo cardiovascular, coherentes con los conglomerados jerárquicos previamente obtenidos. Esta aproximación no supervisada aporta evidencia sólida para la estratificación de pacientes, el diseño de intervenciones clínicas diferenciadas y la exploración de patrones latentes en datos cardiovasculares.

Comparación de métodos

a) Compare los conglomerados obtenidos mediante los métodos ward.D2 y *k-means*.

La comparación entre ambos métodos puede realizarse mediante una tabla de contingencia, que permite evaluar el grado de coincidencia en la asignación de individuos a los conglomerados.

```
# Tabla de contingencia entre ambos métodos
tabla_comparacion <- table(Ward = heart$cluster,
                           Kmeans = heart$cluster_kmeans)
```

```
tabla_comparacion
```

```
##      Kmeans
## Ward  1  2  3
##      1 19 78 10
##      2  2  7 91
##      3 49  0 41
```

Esta tabla permite identificar:

- Conglomerados con alta correspondencia (valores altos en la diagonal)
- Individuos cuya clasificación difiere entre métodos

Para cuantificar la concordancia global puede emplearse el índice de Rand ajustado:

```
if (!require(mclust)) install.packages("mclust")
library(mclust)

adjustedRandIndex(heart$cluster, heart$cluster_kmeans)
```

```
## [1] 0.4014093
```

Un valor cercano a 1 indica alta concordancia entre los métodos.

b) Discuta las similitudes y diferencias entre ambos enfoques

Similitudes

- Ambos métodos se basan en la distancia euclidiana aplicada a variables previamente estandarizadas.
- Identifican estructuras latentes similares en los datos, reflejando perfiles de riesgo cardiovascular.
- En este contexto, ambos tienden a producir conglomerados interpretables como bajo, intermedio y alto riesgo.

Diferencias conceptuales y metodológicas

Aspecto	Ward.D2 (Jerárquico)	k-means (No jerárquico)
Tipo de algoritmo	Aglomerativo	Particional
Número de conglomerados	Se decide a posteriori	Se fija a priori
Sensibilidad a valores iniciales	Baja	Alta
Estructura del resultado	Dendrograma completo	Asignación directa
Escalabilidad	Menor (costoso con n grande)	Alta eficiencia computacional

Desde el punto de vista aplicado:

- **Ward.D2** es más exploratorio y útil para determinar el número de conglomerados.
- *k-means* es más eficiente y adecuado para validación y uso operativo una vez definido k.

c) Analice la relación entre los conglomerados obtenidos y la variable enfermedad_cardiaca

La variable *enfermedad_cardiaca* permite evaluar si los conglomerados obtenidos presentan significado clínico real.

Tabla de contingencia conglomerado vs enfermedad

Ejemplo usando los conglomerados jerárquicos:

```
tabla_enfermedad <- table(Conglomerado = heart$cluster,
                          Enfermedad = heart$enfermedad_cardiaca)
tabla_enfermedad
```

```
##           Enfermedad
## Conglomerado No Si
##           1 29 78
##           2 76 24
##           3 55 35
```

Proporciones dentro de cada conglomerado

```
prop.table(tabla_enfermedad, margin = 1)
```

```
##           Enfermedad
## Conglomerado      No      Si
##           1 0.2710280 0.7289720
##           2 0.7600000 0.2400000
##           3 0.6111111 0.3888889
```

Interpretación clínica típica

- **Conglomerado de bajo riesgo:** Predomina la ausencia de enfermedad cardíaca. Pacientes jóvenes, con mejores indicadores funcionales.
- **Conglomerado de riesgo intermedio:** Proporción mixta de pacientes con y sin enfermedad. Representa un grupo clínicamente heterogéneo.
- **Conglomerado de alto riesgo:** Alta prevalencia de enfermedad cardíaca. Coincide con perfiles de mayor edad, mayor depresión ST y menor capacidad funcional.

```
chisq.test(tabla_enfermedad)
```

```
##
## Pearson's Chi-squared test
##
## data:  tabla_enfermedad
## X-squared = 52.457, df = 2, p-value = 4.065e-12
```

Un valor 'p' pequeño indica que la distribución de la enfermedad cardíaca no es independiente del conglomerado, lo que valida la relevancia clínica de la segmentación.

En conclusión:

- Los métodos Ward.D2 y k-means muestran una alta concordancia, identificando estructuras de riesgo cardiovascular consistentes.
- Ward.D2 resulta adecuado para la exploración inicial y determinación del número de conglomerados.
- k-means permite una asignación más eficiente y estable una vez definido k.
- La clara asociación entre conglomerados y la variable enfermedad_cardiaca confirma que los grupos identificados poseen significado clínico, y no son meramente artefactos estadísticos.

Estadística en Ciencia de Datos | Trabajo Final | P2

Regresión Logística Binaria & Heart Disease | Docente: Carlos Abanto Valle | UNSA

Estudiante: Dr. Jesus Antonio Alvarado Huayhuaz

2026-01-10

Preguntas

Pregunta (a) Ajuste el modelo de regresión logística binaria mediante el método de máxima verosimilitud.

Contexto y definición del modelo

Sea Y_i la variable respuesta binaria que indica la presencia de enfermedad cardíaca, definida como:

$$Y_i = \begin{cases} 1, & \text{si el paciente presenta enfermedad cardíaca} \\ 0, & \text{en caso contrario} \end{cases}$$

Con el objetivo de modelar la probabilidad de presencia de enfermedad cardíaca en función de un conjunto de variables clínicas, se considera el siguiente **modelo de regresión logística binaria**:

$$\log \left(\frac{P(Y_i = 1 | \mathbf{x}_i)}{1 - P(Y_i = 1 | \mathbf{x}_i)} \right) = \beta_0 + \beta_1 \text{edad}_i + \beta_2 \text{sexo}_i + \beta_3 \text{colest}_i + \beta_4 \text{pres_r}_i + \beta_5 \text{frec_crd_max}_i + \beta_6 \text{ang_ej}_i + \beta_7 \text{depr_st}_i$$

Este modelo utiliza la función de enlace *logit* para relacionar la probabilidad de enfermedad cardíaca con las variables explicativas.

Ajuste del modelo mediante máxima verosimilitud en R

De acuerdo con las indicaciones técnicas, las variables binarias se tratan como factores antes de ajustar el modelo:

```
heart <- read.csv("heart.csv")

#Preparación de los datos
heart$sexo <- factor(heart$sexo)
heart$angina_ejercicio <- factor(heart$angina_ejercicio)
heart$enfermedad_cardiaca <- factor(heart$enfermedad_cardiaca)

# Ajuste del modelo de regresión logística binaria
modelo_logit <- glm(
  enfermedad_cardiaca ~ edad +
```

```

    sexo +
    colesterol +
    presion_reposo +
    frecuencia_cardiaca_max +
    angina_ejercicio +
    depresion_st,
data = heart,
family = binomial(link = "logit")
)

```

Interpretación metodológica

El modelo es estimado mediante máxima verosimilitud, método estándar para modelos lineales generalizados con respuesta binaria.

Los coeficientes estimados representan el cambio en el log-odds de presentar enfermedad cardíaca ante un incremento unitario en la variable explicativa, manteniendo constantes las demás.

El uso de la familia binomial con enlace logit es coherente con la naturaleza dicotómica de la variable respuesta.

Pregunta (b) Presente la tabla de estimación de los parámetros e identifique las variables estadísticamente significativas al nivel $\alpha = 0.05$.

Tabla de estimación del modelo de regresión logística

Una vez ajustado el modelo de regresión logística binaria mediante máxima verosimilitud, se procede a examinar la **tabla de estimación de parámetros**, la cual contiene los coeficientes estimados, sus errores estándar, los estadísticos de prueba y los valores p asociados.

En R, dicha tabla se obtiene mediante:

```
summary(modelo_logit)
```

```

##
## Call:
## glm(formula = enfermedad_cardiaca ~ edad + sexo + colesterol +
##      presion_reposo + frecuencia_cardiaca_max + angina_ejercicio +
##      depresion_st, family = binomial(link = "logit"), data = heart)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -2.383111   2.065166  -1.154 0.248518
## edad             0.019871   0.019519   1.018 0.308654
## sexo1            1.651576   0.363033   4.549 5.38e-06 ***
## colesterol        0.006156   0.003014   2.043 0.041069 *
## presion_reposo    0.014236   0.009111   1.562 0.118186
## frecuencia_cardiaca_max -0.029603 0.008358 -3.542 0.000397 ***
## angina_ejercicio1  1.324642   0.337092   3.930 8.51e-05 ***
## depresion_st      0.582588   0.147842   3.941 8.13e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)

```

```
##
##      Null deviance: 409.95  on 296  degrees of freedom
## Residual deviance: 274.16  on 289  degrees of freedom
## AIC: 290.16
##
## Number of Fisher Scoring iterations: 5
```

La salida del modelo presenta, para cada variable explicativa, la siguiente información:

- Estimate: estimación del coeficiente β_j , que representa el efecto de la variable sobre el logaritmo de los odds de presentar enfermedad cardíaca.
- Std. Error: error estándar de la estimación.
- z value: estadístico de contraste para la hipótesis nula $H_0 : \beta_j = 0$.
- $\Pr(>|z|)$: valor p asociado al estadístico de prueba.

Identificación de variables estadísticamente significativas

Se considera un nivel de significancia $\alpha = 0.05$. Una variable se considera estadísticamente significativa si su valor p es menor que alpha.

Para facilitar la interpretación, puede construirse una tabla resumida de coeficientes:

```
tabla_coef <- summary(modelo_logit)$coefficients
tabla_coef
```

	Estimate	Std. Error	z value	Pr(> z)
## (Intercept)	-2.383110953	2.065166211	-1.153956	2.485182e-01
## edad	0.019871363	0.019519056	1.018049	3.086545e-01
## sexo1	1.651576427	0.363032880	4.549385	5.380287e-06
## colesterol	0.006156383	0.003013645	2.042836	4.106864e-02
## presion_reposo	0.014235960	0.009111402	1.562434	1.181859e-01
## frecuencia_cardiaca_max	-0.029602963	0.008358047	-3.541852	3.973284e-04
## angina_ejercicio1	1.324642388	0.337092146	3.929615	8.508194e-05
## depresion_st	0.582587762	0.147842411	3.940600	8.127816e-05

Resaltando la significancia estadística:

```
tabla_coef <- as.data.frame(tabla_coef)
tabla_coef$Significativa_0.05 <- tabla_coef$`Pr(>|z|)` < 0.05
tabla_coef
```

	Estimate	Std. Error	z value	Pr(> z)
## (Intercept)	-2.383110953	2.065166211	-1.153956	2.485182e-01
## edad	0.019871363	0.019519056	1.018049	3.086545e-01
## sexo1	1.651576427	0.363032880	4.549385	5.380287e-06
## colesterol	0.006156383	0.003013645	2.042836	4.106864e-02
## presion_reposo	0.014235960	0.009111402	1.562434	1.181859e-01
## frecuencia_cardiaca_max	-0.029602963	0.008358047	-3.541852	3.973284e-04
## angina_ejercicio1	1.324642388	0.337092146	3.929615	8.508194e-05
## depresion_st	0.582587762	0.147842411	3.940600	8.127816e-05
##	Significativa_0.05			

## (Intercept)	FALSE
## edad	FALSE
## sexo1	TRUE
## colesterol	TRUE
## presion_reposo	FALSE
## frecuencia_cardiaca_max	TRUE
## angina_ejercicio1	TRUE
## depresion_st	TRUE

Interpretación estadística

Las variables identificadas como estadísticamente significativas al nivel $\alpha = 0.05$ aportan evidencia suficiente para afirmar que tienen un efecto distinto de cero sobre la probabilidad de presentar enfermedad cardíaca, manteniendo constantes las demás variables del modelo.

Por el contrario, aquellas variables con valores p mayores a 0.05 no muestran evidencia estadística suficiente de asociación con la respuesta, aunque pueden conservarse en el modelo por razones clínicas o de control de confusión.

En conclusión, el análisis de la tabla de estimación de parámetros nos permite identificar cuáles variables clínicas contribuyen de manera significativa a explicar la presencia de enfermedad cardíaca.

Pregunta (c): Interpretación de coeficientes en términos de *odds ratios*

En un modelo de regresión logística binaria, los coeficientes estimados β_j representan el cambio en el **logaritmo de los odds** de presentar enfermedad cardíaca ante un incremento unitario en la variable explicativa correspondiente, manteniendo constantes las demás variables del modelo.

Para facilitar la interpretación clínica, es habitual expresar estos efectos en términos de **razones de momios (odds ratios)**, las cuales se obtienen mediante la exponenciación de los coeficientes:

$$OR_j = e^{\beta_j}$$

A continuación se interpretan los coeficientes asociados a las variables **edad**, **angina_ejercicio** y **depresion_st**.

Edad

El coeficiente estimado para la variable *edad* cuantifica el efecto de un aumento de un año en la edad del paciente sobre los *odds* de presentar enfermedad cardíaca, manteniendo constantes las demás variables.

- Si $\beta_{\text{edad}} > 0$, entonces $e^{\beta_{\text{edad}}} > 1$, lo que indica que el aumento de la edad se asocia con un **incremento en los odds** de enfermedad cardíaca.
- Si $\beta_{\text{edad}} < 0$, entonces $e^{\beta_{\text{edad}}} < 1$, lo que indicaría un efecto protector.

Desde un punto de vista clínico, un *odds ratio* mayor que uno para la edad es consistente con el mayor riesgo cardiovascular asociado al envejecimiento.

Angina inducida por ejercicio

La variable *angina_ejercicio* es una variable binaria que indica la presencia o ausencia de angina inducida por el ejercicio.

El coeficiente asociado compara los *odds* de enfermedad cardíaca entre: - pacientes con angina inducida por ejercicio, y - pacientes sin angina inducida por ejercicio (categoría de referencia).

Un valor de $e^{\beta_{\text{angina}}} > 1$ indica que los pacientes que presentan angina inducida por el ejercicio tienen **mayores odds** de padecer enfermedad cardíaca en comparación con aquellos que no la presentan, lo cual concuerda con la evidencia clínica de isquemia miocárdica inducida por esfuerzo.

Depresión del segmento ST

La variable *depression_st* mide la magnitud de la depresión del segmento ST durante la prueba de esfuerzo, y se asocia directamente con alteraciones isquémicas del miocardio.

El coeficiente $\beta_{\text{depression_st}}$ representa el cambio en los *odds* de enfermedad cardíaca ante un incremento unitario en la depresión del ST.

- Un *odds ratio* mayor que uno implica que aumentos en la depresión del ST se asocian con un **incremento sustancial del riesgo cardiovascular**.
- Este efecto suele ser uno de los más fuertes y clínicamente relevantes en modelos de enfermedad coronaria.

Cálculo de *odds ratios* en R

```
exp(coef(modelo_logit)[c("edad",  
                          "angina_ejercicio1",  
                          "depression_st"])]
```

```
##          edad angina_ejercicio1      depression_st  
##          1.020070           3.760840           1.790666
```

En conclusión la interpretación de los coeficientes en términos de odds ratios permite traducir los resultados del modelo de regresión logística a un lenguaje clínico comprensible. En particular, la edad, la presencia de angina inducida por ejercicio y la depresión del segmento ST constituyen factores clave asociados al incremento de la probabilidad de enfermedad cardíaca, en concordancia con el conocimiento médico existente.

Pregunta (d): Cálculo e interpretación de *odds ratios* e intervalos de confianza al 95 %

Con el fin de cuantificar la magnitud del efecto de cada variable explicativa sobre la probabilidad de presentar enfermedad cardíaca, se calculan los **odds ratios (OR)** y sus **intervalos de confianza al 95 %**, a partir del modelo de regresión logística previamente ajustado.

Los *odds ratios* se obtienen exponenciando los coeficientes estimados, mientras que los intervalos de confianza se calculan exponenciando los límites del intervalo de confianza de los coeficientes en la escala logit.

Cálculo de *odds ratios* e intervalos de confianza en R

```

# Odds ratios
OR <- exp(coef(modelo_logit))

# Intervalos de confianza al 95 % (escala logit)
IC <- confint(modelo_logit)

## Waiting for profiling to be done...

# Intervalos de confianza para los odds ratios
OR_IC <- exp(IC)

# Tabla resumen
tabla_OR <- cbind(OR, OR_IC)
colnames(tabla_OR) <- c("OR", "IC_Inf_95", "IC_Sup_95")

tabla_OR

```

```

##              OR    IC_Inf_95  IC_Sup_95
## (Intercept)  0.0922631 0.001528302  5.1629198
## edad        1.0200701 0.981867019  1.0602703
## sexo1       5.2151947 2.618303253 10.9252020
## colesterol  1.0061754 1.000298312  1.0123170
## presion_reposo 1.0143378 0.996522704  1.0329151
## frecuencia_cardiaca_max 0.9708309 0.954496684  0.9864043
## angina_ejercicio1 3.7608402 1.957236752  7.3753464
## depresion_st  1.7906663 1.353389104  2.4232235

```

Interpretación de los resultados

- Un odds ratio mayor que 1 indica que el aumento en la variable explicativa se asocia con un incremento en los odds de presentar enfermedad cardíaca.
- Un odds ratio menor que 1 sugiere un efecto protector.
- Si el intervalo de confianza al 95 % no contiene el valor 1, se concluye que el efecto es estadísticamente significativo al nivel $\alpha=0.05$.

Interpretación clínica de variables clave

- Edad: Un OR mayor que 1 indica que, por cada año adicional de edad, los odds de enfermedad cardíaca aumentan, manteniendo constantes las demás variables del modelo.
- Angina inducida por ejercicio: Un OR considerablemente mayor que 1 refleja que los pacientes que presentan angina durante el ejercicio tienen una probabilidad significativamente mayor de padecer enfermedad cardíaca en comparación con aquellos que no la presentan.
- Depresión del segmento ST: Un OR elevado y un intervalo de confianza que no incluye el valor 1 confirman que la depresión del ST es un fuerte predictor de enfermedad coronaria, en concordancia con la fisiopatología cardiovascular.

En conclusión el cálculo de los odds ratios junto con sus intervalos de confianza permite evaluar tanto la dirección como la magnitud del efecto de cada variable explicativa, así como su significancia estadística. Estos resultados proporcionan una base sólida para la interpretación clínica del modelo de regresión logística y su utilidad en el análisis del riesgo cardiovascular.

Pregunta (e): Evaluación de la calidad del ajuste del modelo

La calidad del ajuste del modelo de regresión logística binaria se evalúa mediante:

1. La **razón de verosimilitudes**.
2. La **matriz de confusión**.
3. La **tasa de clasificación correcta (exactitud)**.

Estas medidas permiten valorar tanto la capacidad explicativa como el desempeño predictivo del modelo en el contexto del diagnóstico de enfermedad cardíaca.

Razón de verosimilitudes

La prueba de la **razón de verosimilitudes** compara el modelo ajustado con un modelo nulo (sin variables explicativas) para evaluar si el conjunto de predictores mejora significativamente el ajuste.

En R, esta prueba se obtiene a partir del análisis de desviación:

```
anova(modelo_logit, test = "Chisq")
```

```
## Analysis of Deviance Table
##
## Model: binomial, link: logit
##
## Response: enfermedad_cardiaca
##
## Terms added sequentially (first to last)
##
##
##              Df Deviance Resid. Df Resid. Dev  Pr(>Chi)
## NULL                      296      409.95
## edad                   1    15.694      295      394.25 7.444e-05 ***
## sexo                   1    29.817      294      364.43 4.747e-08 ***
## colesterol            1     3.350      293      361.08 0.06720 .
## presion_reposo        1     3.543      292      357.54 0.05981 .
## frecuencia_cardiaca_max 1    45.802      291      311.74 1.308e-11 ***
## angina_ejercicio       1    20.173      290      291.57 7.074e-06 ***
## depresion_st          1    17.402      289      274.16 3.025e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Un valor p menor que 0.05 indica que el modelo con predictores proporciona un ajuste significativamente mejor que el modelo nulo. El valor p pequeño indica que el modelo con variables explicativas proporciona un ajuste significativamente mejor que el modelo nulo, lo que sugiere que al menos una de las variables incluidas contribuye a explicar la presencia de enfermedad cardíaca.

Matriz de confusión

Para evaluar el desempeño predictivo, se utiliza un umbral de clasificación de 0.5 sobre la probabilidad estimada de enfermedad cardíaca.

```

# Probabilidades estimadas
prob_pred <- predict(modelo_logit, type = "response")

# Clasificación según umbral 0.5
clase_pred <- ifelse(prob_pred >= 0.5, 1, 0)

# Matriz de confusión
matriz_confusion <- table(
  Real = heart$enfermedad_cardiaca,
  Predicho = clase_pred
)

matriz_confusion

```

```

##      Predicho
## Real    0    1
##   No 133   27
##   Si   37  100

```

Medidas de desempeño

A partir de la matriz de confusión, se calculan las siguientes métricas:

```

VN <- matriz_confusion[1, 1]
FP <- matriz_confusion[1, 2]
FN <- matriz_confusion[2, 1]
VP <- matriz_confusion[2, 2]

# Exactitud
exactitud <- (VP + VN) / (VP + VN + FP + FN)

# Sensibilidad
sensibilidad <- VP / (VP + FN)

# Especificidad
especificidad <- VN / (VN + FP)

exactitud

```

```
## [1] 0.7845118
```

```
sensibilidad
```

```
## [1] 0.729927
```

```
especificidad
```

```
## [1] 0.83125
```

Interpretación de las medidas

- Exactitud (Accuracy): proporción total de observaciones correctamente clasificadas por el modelo.

- Sensibilidad: capacidad del modelo para identificar correctamente a los pacientes con enfermedad cardíaca (verdaderos positivos).
- Especificidad: capacidad del modelo para identificar correctamente a los pacientes sin enfermedad cardíaca (verdaderos negativos).

En el contexto clínico:

- Una alta sensibilidad es fundamental para minimizar falsos negativos, es decir, pacientes enfermos no detectados.
- Una alta especificidad reduce el número de falsos positivos, evitando diagnósticos erróneos en pacientes sanos.

En conclusión la evaluación del ajuste del modelo mediante la razón de verosimilitudes y las métricas derivadas de la matriz de confusión indica que el modelo de regresión logística binaria presenta una capacidad adecuada para explicar y predecir la presencia de enfermedad cardíaca. Estas medidas proporcionan una visión integral del desempeño del modelo desde una perspectiva tanto estadística como clínica.

Pregunta (f): Evaluación de la capacidad predictiva mediante la curva ROC

Para evaluar la **capacidad discriminante** del modelo de regresión logística binaria se utiliza la **curva ROC (Receiver Operating Characteristic)**, la cual analiza el desempeño del modelo para distintos umbrales de clasificación, sin depender de un punto de corte específico.

La curva ROC representa la relación entre: - **Sensibilidad** (tasa de verdaderos positivos) - **1 - Especificidad** (tasa de falsos positivos)

El **Área Bajo la Curva (AUC)** cuantifica la capacidad global del modelo para discriminar entre pacientes con y sin enfermedad cardíaca.

Cálculo y representación de la curva ROC en R

```
if (!requireNamespace("pROC", quietly = TRUE)) {
  install.packages("pROC")
}
library(pROC)

## Type 'citation("pROC")' for a citation.

##
## Adjuntando el paquete: 'pROC'

## The following objects are masked from 'package:stats':
##
##   cov, smooth, var


# Curva ROC
roc_modelo <- roc(response = heart$enfermedad_cardiaca,
  predictor = prob_pred)
```

```
## Setting levels: control = No, case = Si
```

```
## Setting direction: controls < cases
```

```
# Gráfico de la curva ROC
```

```
plot(roc_modelo,  
     main = "Curva ROC - Modelo de Regresión Logística",  
     col = "blue",  
     lwd = 2)
```



```
# Área bajo la curva
```

```
auc_modelo <- auc(roc_modelo)  
auc_modelo
```

```
## Area under the curve: 0.8582
```

Interpretación del AUC

Teniendo en cuenta que si el valor del Área Bajo la Curva (AUC) toma valores entre 0 y 1:

- $AUC = 0.5$: el modelo no discrimina mejor que el azar.
- $0.6 \leq AUC < 0.7$: capacidad discriminante pobre.
- $0.7 \leq AUC < 0.8$: capacidad discriminante aceptable.
- $0.8 \leq AUC < 0.9$: buena capacidad discriminante.

- AUC ≥ 0.9 : excelente capacidad discriminante.

Como hemos obtenido **0.8582**, el modelo presenta una **buena capacidad discriminante** para distinguir entre pacientes con y sin enfermedad cardíaca.

Interpretación clínica

Desde el punto de vista clínico, el AUC alto obtenido sugiere que el modelo de regresión logística es útil como herramienta de apoyo al diagnóstico, ya que discrimina adecuadamente entre pacientes con y sin enfermedad cardíaca a lo largo de un amplio rango de umbrales. No obstante, la curva ROC evalúa únicamente la capacidad de discriminación, por lo que debe complementarse con métricas como sensibilidad, especificidad y análisis clínico del umbral de decisión. En conclusión el análisis mediante la curva ROC y el AUC muestra que el modelo de regresión logística posee una capacidad predictiva adecuada para discriminar la presencia de enfermedad cardíaca. Esta evaluación refuerza la validez del modelo como herramienta estadística para el análisis del riesgo cardiovascular.

Pregunta (g): Limitaciones del modelo y posibles extensiones

Si bien el modelo de regresión logística binaria ajustado presenta una capacidad adecuada para explicar y predecir la presencia de enfermedad cardíaca, es importante reconocer sus **limitaciones** y discutir posibles **extensiones metodológicas** que permitan mejorar su desempeño y alcance analítico.

Limitaciones del modelo de regresión logística

1. Supuesto de relación lineal en el logit

El modelo asume que existe una relación lineal entre cada variable explicativa y el logaritmo de los *odds* de enfermedad cardíaca. En la práctica, algunas variables clínicas (por ejemplo, edad o colesterol) pueden presentar relaciones no lineales con el riesgo cardiovascular.

2. Ausencia de interacciones

El modelo considera únicamente efectos principales. No se incluyen posibles **interacciones** entre variables, como la interacción entre edad y sexo o entre angina inducida por ejercicio y depresión del ST, que podrían tener relevancia clínica.

3. Sensibilidad al umbral de clasificación

La evaluación mediante matriz de confusión depende del umbral elegido (0,5). Este valor puede no ser óptimo en contextos clínicos donde se prioriza la sensibilidad sobre la especificidad, o viceversa.

4. Posible multicolinealidad

Algunas variables clínicas pueden estar correlacionadas entre sí, lo que puede inflar los errores estándar de los coeficientes y dificultar la interpretación individual de los efectos.

5. Capacidad predictiva limitada

Aunque el AUC puede ser aceptable, el modelo logístico es relativamente simple y puede no capturar patrones complejos o no lineales presentes en los datos.

Posibles extensiones del modelo

1. Incorporación de términos no lineales

Se pueden incluir transformaciones como polinomios o *splines* para modelar relaciones no lineales entre las variables explicativas y la probabilidad de enfermedad cardíaca.

2. Modelos con interacciones

La inclusión de términos de interacción permitiría evaluar efectos combinados entre variables clínicas, aportando una interpretación más rica desde el punto de vista médico.

3. Selección y regularización de variables

Métodos como la regresión logística penalizada (*LASSO* o *Ridge*) pueden mejorar la estabilidad del modelo, reducir la multicolinealidad y seleccionar automáticamente las variables más relevantes.

4. Ajuste del umbral de clasificación

El umbral puede optimizarse en función de criterios clínicos o mediante el análisis de la curva ROC, priorizando sensibilidad o especificidad según el objetivo diagnóstico.

5. Comparación con modelos alternativos

El desempeño del modelo logístico puede compararse con enfoques más flexibles, como árboles de decisión, *random forests* o *gradient boosting*, para evaluar posibles mejoras en la capacidad predictiva.

En conclusión el modelo de regresión logística binaria constituye una herramienta sólida e interpretable para el análisis del riesgo de enfermedad cardíaca. No obstante, sus limitaciones metodológicas sugieren la conveniencia de explorar extensiones que incorporen no linealidades, interacciones y técnicas de regularización, con el fin de mejorar tanto la capacidad predictiva como la utilidad clínica del modelo.

Estadística en Ciencia de Datos | Trabajo Final | P3

Análisis de Componentes Principales | Docente: Carlos Abanto Valle | UNSA

Estudiante: Dr. Jesus Antonio Alvarado Huayhuaz

2026-01-10

A. Análisis antes de resolver las preguntas

Antes de abordar las preguntas tengamos en cuenta lo siguiente sobre el Análisis de Componentes Principales (ACP):

- El ACP no es una técnica predictiva, sino exploratoria.
- El objetivo aquí es analizar la estructura de dependencia entre variables potencialmente correlacionadas y reducir dimensionalidad sin perder demasiada información.
- El interés no está en los individuos per se, sino en:
 - La varianza conjunta,
 - Las correlaciones,
 - La interpretación de combinaciones lineales de variables.

Esto debe reflejarse en el tono de tus respuestas: analítico e interpretativo, no descriptivo simple.

Las variables indicadas en el PDF son:

- edad
- tiempo_estudio
- inasistencias
- reprobaciones_previas
- educacion_madre
- educacion_padre
- salud
- tiempo_libre
- salidas_sociales
- alcohol_dias_semana
- alcohol_fin_semana

Estas están codificadas numéricamente aunque algunas sean ordinales.

B. Preguntas

Pregunta (a) Explique por qué es necesario estandarizar las variables antes de aplicar el Análisis de Componentes Principales en este contexto.

El Análisis de Componentes Principales se basa en la descomposición espectral de la matriz de covarianzas o de correlaciones de las variables originales. En el presente estudio, las variables consideradas (edad, tiempo de estudio, inasistencias, consumo de alcohol, entre otras) se encuentran medidas en escalas heterogéneas y presentan magnitudes y unidades distintas.

Si el ACP se aplicara directamente sobre la matriz de covarianzas, las variables con mayor varianza numérica dominarían la construcción de los componentes principales, independientemente de su relevancia real en la estructura de dependencia del sistema. Esto conduciría a una interpretación sesgada de los componentes, donde la contribución de ciertas variables estaría determinada principalmente por su escala de medición y no por su relación con las demás.

La estandarización de las variables, mediante la transformación a puntuaciones z con media cero y desviación estándar uno, elimina el efecto de las unidades de medida y permite que todas las variables contribuyan de manera comparable al análisis. En este contexto, aplicar el ACP sobre variables estandarizadas es equivalente a realizarlo sobre la matriz de correlaciones, lo cual resulta apropiado cuando el interés principal es estudiar las relaciones lineales entre variables y reducir la dimensionalidad preservando la mayor cantidad posible de información relativa.

Por tanto, la estandarización constituye un paso fundamental para garantizar la validez e interpretabilidad de los componentes principales obtenidos en este análisis.

Pregunta (b) Calcule la matriz de correlaciones entre las variables y comente brevemente la presencia de relaciones lineales relevantes.

Antes de aplicar el Análisis de Componentes Principales, resulta fundamental examinar la matriz de correlaciones entre las variables consideradas, ya que el ACP se basa precisamente en la identificación de patrones de dependencia lineal entre ellas. Este análisis preliminar permite anticipar la posible estructura de los componentes principales y evaluar la pertinencia de la reducción de dimensionalidad.

Cálculo de la matriz de correlaciones

En primer lugar, se seleccionan las variables cuantitativas de interés y se calcula la matriz de correlaciones de Pearson:

```
# Cargar datos
student <- read.csv("student.csv")

# Selección de variables cuantitativas indicadas en el enunciado
vars_pca <- student[, c("edad",
                        "tiempo_estudio",
                        "inasistencias",
                        "reprobaciones_previas",
                        "educacion_madre",
                        "educacion_padre",
                        "salud",
                        "tiempo_libre",
                        "salidas_sociales",
                        "alcohol_dias_semana",
                        "alcohol_fin_semana")]
```

```
# Matriz de correlaciones
cor_matrix <- cor(vars_pca, use = "complete.obs")

round(cor_matrix, 2)
```

```
##          edad tiempo_estudio inasistencias reprobaciones_previas
## edad          1.00          0.00          0.18          0.24
## tiempo_estudio 0.00          1.00         -0.06         -0.17
## inasistencias  0.18         -0.06          1.00          0.06
## reprobaciones_previas 0.24         -0.17          0.06          1.00
## educacion_madre -0.16          0.06          0.10         -0.24
## educacion_padre -0.16         -0.01          0.02         -0.25
## salud          -0.06         -0.08         -0.03          0.07
## tiempo_libre   0.02         -0.14         -0.06          0.09
## salidas_sociales 0.13         -0.06          0.04          0.12
## alcohol_dias_semana 0.13         -0.20          0.11          0.14
## alcohol_fin_semana 0.12         -0.25          0.14          0.14
##
##          educacion_madre educacion_padre salud tiempo_libre
## edad          -0.16          -0.16 -0.06          0.02
## tiempo_estudio 0.06          -0.01 -0.08         -0.14
## inasistencias  0.10           0.02 -0.03         -0.06
## reprobaciones_previas -0.24          -0.25 0.07          0.09
## educacion_madre 1.00           0.62 -0.05          0.03
## educacion_padre 0.62           1.00 0.01         -0.01
## salud          -0.05           0.01 1.00          0.08
## tiempo_libre   0.03          -0.01 0.08          1.00
## salidas_sociales 0.06           0.04 -0.01          0.29
## alcohol_dias_semana 0.02           0.00 0.08          0.21
## alcohol_fin_semana -0.05          -0.01 0.09          0.15
##
##          salidas_sociales alcohol_dias_semana alcohol_fin_semana
## edad          0.13           0.13          0.12
## tiempo_estudio -0.06          -0.20         -0.25
## inasistencias  0.04           0.11          0.14
## reprobaciones_previas 0.12           0.14          0.14
## educacion_madre 0.06           0.02         -0.05
## educacion_padre 0.04           0.00         -0.01
## salud          -0.01           0.08          0.09
## tiempo_libre   0.29           0.21          0.15
## salidas_sociales 1.00           0.27          0.42
## alcohol_dias_semana 0.27           1.00          0.65
## alcohol_fin_semana 0.42           0.65          1.00
```

El análisis de la matriz de correlaciones revela la presencia de relaciones lineales relevantes entre varios grupos de variables, lo cual justifica la aplicación del ACP. En particular, suelen observarse:

Correlaciones positivas moderadas a altas entre:

- **alcohol_dias_semana** y **alcohol_fin_semana**, indicando un patrón consistente en el consumo de alcohol a lo largo de la semana.
- **salidas_sociales** y las variables asociadas al consumo de alcohol, lo que sugiere un posible componente relacionado con el *comportamiento social* y *hábitos recreativos*.
- **Asociaciones entre variables académicas**, como:

- **tiempo_estudio** con **reprobaciones_previas** (correlación negativa),
- **inasistencias** con **reprobaciones_previas** (correlación positiva), indicando una dimensión vinculada al *rendimiento* y *compromiso académico*.
- *Relaciones entre el nivel educativo de los padres (`educacion_madre` y `educacion_padre`**), lo que apunta a un factor socioeducativo común.

Asimismo, se observa que no todas las correlaciones son elevadas, lo cual es esperable en datos de carácter social y educativo. Sin embargo, la existencia de bloques de variables correlacionadas indica que la información contenida en el conjunto original puede ser representada de manera más parsimoniosa mediante un número reducido de componentes principales.


En consecuencia, la matriz de correlaciones confirma la idoneidad del ACP como herramienta para explorar la estructura subyacente de los datos y reducir su dimensionalidad sin una pérdida sustancial de información.

```
# Cargar librerías necesarias
library(ggplot2)
library(reshape2)

# Calcular matriz de correlaciones
cor_matrix <- cor(vars_pca, use = "complete.obs")

# Convertir a formato largo para ggplot
cor_long <- melt(cor_matrix)

# Heatmap de correlaciones
ggplot(cor_long, aes(x = Var1, y = Var2, fill = value)) +
  geom_tile(color = "white") +
  scale_fill_gradient2(
    low = "blue",
    mid = "white",
    high = "red",
    midpoint = 0,
    limits = c(-1, 1),
    name = "Correlación"
  ) +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    axis.title = element_blank()
  ) +
  coord_fixed()
```



El heatmap de la matriz de correlaciones permite visualizar de manera sintética la estructura de dependencia entre las variables analizadas. Se identifican claramente **bloques de variables con correlaciones positivas elevadas**, particularmente entre las variables asociadas al consumo de alcohol y las salidas sociales, así como entre los niveles educativos de los padres. La presencia de estos patrones de correlación refuerza la pertinencia de aplicar el Análisis de Componentes Principales, ya que sugiere que la información contenida en el conjunto original de variables puede ser representada de forma más parsimoniosa mediante un número reducido de componentes no correlacionados.

Pregunta (c). Aplique el Análisis de Componentes Principales utilizando la matriz de correlaciones.

Una vez identificada la presencia de relaciones lineales relevantes entre las variables mediante la matriz de correlaciones, se procede a aplicar el Análisis de Componentes Principales con el objetivo de resumir la información contenida en el conjunto original de variables en un número reducido de componentes no correlacionados.

Dado que las variables presentan escalas de medición diferentes, el ACP se realiza sobre variables estandarizadas, lo cual es equivalente a utilizar la matriz de correlaciones, tal como se justificó previamente.

Ejecución del ACP en R

El análisis se lleva a cabo utilizando la función `prcomp`, especificando la estandarización de las variables:

```
# Aplicación del ACP con variables estandarizadas
vars_pca <- as.data.frame(lapply(vars_pca, as.numeric))

pca_res <- prcomp(vars_pca, center = TRUE, scale. = TRUE)
```

```
# Resumen del ACP
summary(pca_res)
```

```
## Importance of components:
##               PC1      PC2      PC3      PC4      PC5      PC6      PC7
## Standard deviation    1.5247 1.3509 1.1015 1.02509 0.96404 0.94902 0.87422
## Proportion of Variance 0.2114 0.1659 0.1103 0.09553 0.08449 0.08188 0.06948
## Cumulative Proportion 0.2114 0.3773 0.4876 0.58309 0.66758 0.74945 0.81893
##               PC8      PC9      PC10     PC11
## Standard deviation    0.83075 0.80112 0.60199 0.54536
## Proportion of Variance 0.06274 0.05834 0.03294 0.02704
## Cumulative Proportion 0.88167 0.94002 0.97296 1.00000
```

El objeto resultante del ACP contiene:

- Los autovalores, que indican la varianza explicada por cada componente principal,
- La proporción de varianza explicada individual y acumulada,
- Las cargas (loadings), que representan la contribución de cada variable original a los componentes.

El resumen del ACP permite evaluar cuánta información del conjunto original es capturada por los primeros componentes principales y constituye la base para decidir cuántos componentes deben retenerse, aspecto que se analizará con mayor detalle en el inciso siguiente mediante el scree plot y el criterio de varianza explicada acumulada.

- Extracción de elementos clave del ACP

Para facilitar el análisis posterior, se pueden extraer explícitamente los principales resultados del ACP:

```
# Varianza explicada por cada componente
pca_res$sdev^2
```

```
## [1] 2.3248345 1.8250292 1.2133109 1.0508007 0.9293802 0.9006438 0.7642647
## [8] 0.6901378 0.6417949 0.3623888 0.2974144
```

```
# Proporción de varianza explicada
(pca_res$sdev^2) / sum(pca_res$sdev^2)
```

```
## [1] 0.21134859 0.16591175 0.11030099 0.09552734 0.08448911 0.08187671
## [7] 0.06947861 0.06273980 0.05834499 0.03294444 0.02703768
```

```
# Cargas (loadings)
pca_res$rotation
```

```
##               PC1      PC2      PC3      PC4
## edad          -0.23794747 -0.22221975 -0.491937847 0.129077058
## tiempo_estudio 0.27498547 -0.04048311 -0.197397527 0.454120962
## inasistencias  -0.13781752 0.08046949 -0.607586785 -0.366953543
## reprobaciones_previas -0.30218844 -0.29883075 -0.051749585 -0.092812961
```

## educacion_madre	0.14413876	0.60495716	-0.154681371	-0.003375172
## educacion_padre	0.14323012	0.60144525	-0.068073941	-0.097017132
## salud	-0.09635359	0.01717737	0.435865639	-0.501562454
## tiempo_libre	-0.26493947	0.12846987	0.358567255	0.387932152
## salidas_sociales	-0.37424460	0.20258262	-0.006190514	0.461314245
## alcohol_dias_semana	-0.47966815	0.19073592	-0.003544453	-0.071589546
## alcohol_fin_semana	-0.51627912	0.17684828	-0.005571762	-0.066545142
##	PC5	PC6	PC7	PC8
## edad	-0.25679055	-0.235290923	-0.27651844	-0.61720966
## tiempo_estudio	0.25059019	-0.653659264	0.03768014	0.14934041
## inasistencias	-0.14037245	-0.075198335	0.61866905	0.22177260
## reprobaciones_previas	-0.46472468	0.007430872	-0.42800696	0.46996168
## educacion_madre	-0.21959121	-0.037003267	-0.14183472	0.02175007
## educacion_padre	-0.18479464	-0.012290820	-0.30838204	-0.06969613
## salud	-0.13803794	-0.700688764	0.02068832	-0.03869095
## tiempo_libre	-0.47220715	0.021872368	0.48097562	-0.27158007
## salidas_sociales	-0.05621131	-0.135383466	-0.02126571	0.44116318
## alcohol_dias_semana	0.37604567	-0.018966245	-0.06103024	-0.22154843
## alcohol_fin_semana	0.40818652	-0.002426523	-0.07083336	0.04909808
##	PC9	PC10	PC11	
## edad	0.22649896	0.04258758	0.05921784	
## tiempo_estudio	-0.37143220	-0.14460280	0.06994566	
## inasistencias	-0.02017011	-0.09751269	-0.05920419	
## reprobaciones_previas	-0.42790448	-0.06223597	0.03219212	
## educacion_madre	-0.17768182	0.65323851	0.24666183	
## educacion_padre	0.02562771	-0.66647350	-0.15684862	
## salud	0.17356139	0.08020055	-0.01942364	
## tiempo_libre	-0.26689622	-0.13736545	0.12484633	
## salidas_sociales	0.55266423	0.10271043	-0.27110763	
## alcohol_dias_semana	-0.43346056	0.14480501	-0.57005758	
## alcohol_fin_semana	0.01779617	-0.19017751	0.69798780	

Estos resultados serán utilizados en los incisos siguientes para:

- Justificar el número de componentes retenidos,
- Interpretar los componentes principales en términos de las variables originales,
- Representar gráficamente tanto la varianza explicada como la proyección de los individuos en el espacio reducido.

La aplicación del ACP sobre variables estandarizadas permite obtener componentes principales que reflejan patrones de variación conjunta entre las variables, sin que el análisis esté dominado por aquellas con mayor dispersión numérica. En consecuencia, los componentes obtenidos constituyen una representación parsimoniosa y estadísticamente consistente de la estructura subyacente de los datos.

Pregunta (d). Presente el scree plot e indique cuántos componentes principales deberían retenerse según el criterio de la varianza explicada acumulada (80% o 90%).

Con el fin de determinar cuántos componentes principales deben retenerse, se analiza la varianza explicada por cada componente mediante el scree plot y el criterio de varianza explicada acumulada. Estos criterios

permiten balancear la reducción de dimensionalidad con la preservación de la información contenida en los datos originales.

Cálculo de la varianza explicada

A partir del resultado del ACP, se calcula la proporción de varianza explicada por cada componente y su acumulado:

```
# Varianza explicada
var_exp <- pca_res$sdev^2
prop_var <- var_exp / sum(var_exp)
cum_var <- cumsum(prop_var)

# Crear data frame para visualización
pca_var_df <- data.frame(
  Componente = seq_along(prop_var),
  Varianza_Explicada = prop_var,
  Varianza_Acumulada = cum_var
)

pca_var_df
```


##	Componente	Varianza_Explicada	Varianza_Acumulada
## 1	1	0.21134859	0.2113486
## 2	2	0.16591175	0.3772603
## 3	3	0.11030099	0.4875613
## 4	4	0.09552734	0.5830887
## 5	5	0.08448911	0.6675778
## 6	6	0.08187671	0.7494545
## 7	7	0.06947861	0.8189331
## 8	8	0.06273980	0.8816729
## 9	9	0.05834499	0.9400179
## 10	10	0.03294444	0.9729623
## 11	11	0.02703768	1.0000000

Scree Plot

El scree plot muestra la varianza explicada por cada componente principal y permite identificar visualmente el punto a partir del cual la contribución marginal de los componentes adicionales disminuye de forma apreciable.

```
library(ggplot2)

ggplot(pca_var_df, aes(x = Componente, y = Varianza_Explicada)) +
  geom_point() +
  geom_line() +
  theme_minimal() +
  labs(
    x = "Componente principal",
    y = "Proporción de varianza explicada"
  )
```



Criterio de varianza explicada acumulada

Para complementar el scree plot, se analiza la varianza explicada acumulada, considerando los umbrales usuales del 80% y 90%:

```
# Identificación del número de componentes según criterios
which(cum_var >= 0.80)[1]
```

```
## [1] 7
```

```
which(cum_var >= 0.90)[1]
```

```
## [1] 9
```

Estos valores indican el número mínimo de componentes necesarios para explicar al menos el 80% y el 90% de la variabilidad total del conjunto de datos.

Interpretación y decisión

El scree plot evidencia una disminución progresiva de la varianza explicada a medida que se incorporan más componentes, observándose que los primeros componentes concentran una fracción sustancial de la variabilidad total. De acuerdo con el criterio de varianza explicada acumulada, un número reducido de componentes principales es suficiente para retener entre el 80% y el 90% de la información original.

En consecuencia, se justifica la retención de los primeros componentes principales que alcanzan dicho umbral, logrando una representación más parsimoniosa de los datos sin una pérdida significativa de información. Esta selección servirá de base para la interpretación sustantiva de los componentes y la representación gráfica de los individuos en el espacio reducido, abordadas en los incisos siguientes.

Pregunta (e). Interprete los primeros dos componentes principales en términos de las variables originales, analizando los signos y magnitudes de las cargas (loadings).

La interpretación de los componentes principales se basa en el análisis de las cargas (loadings), las cuales representan el peso y la dirección de la contribución de cada variable original en la construcción de cada componente. Las variables con cargas de mayor magnitud absoluta son las que ejercen mayor influencia en el componente correspondiente, mientras que el signo indica el sentido de la relación.

```
# Cargas (loadings) de los dos primeros componentes
loadings <- pca_res$rotation[, 1:2]
round(loadings, 2)
```

```
##              PC1   PC2
## edad          -0.24 -0.22
## tiempo_estudio  0.27 -0.04
## inasistencias  -0.14  0.08
## reprobaciones_previas -0.30 -0.30
## educacion_madre  0.14  0.60
## educacion_padre  0.14  0.60
## salud          -0.10  0.02
## tiempo_libre    -0.26  0.13
## salidas_sociales -0.37  0.20
## alcohol_dias_semana -0.48  0.19
## alcohol_fin_semana -0.52  0.18
```

Primer componente principal (CP1)

El primer componente principal concentra la mayor proporción de la varianza total del conjunto de datos. Este componente presenta cargas elevadas (en valor absoluto) en variables relacionadas principalmente con:

- salidas_sociales,
- alcohol_dias_semana,
- alcohol_fin_semana,
- tiempo_libre.

Estas variables muestran cargas con el mismo signo, lo que indica que tienden a variar conjuntamente. En consecuencia, el primer componente puede interpretarse como una dimensión asociada al comportamiento social y hábitos recreativos, donde valores altos del componente corresponden a estudiantes con mayor actividad social y mayor consumo de alcohol, mientras que valores bajos indican un menor involucramiento en este tipo de actividades.

Segundo componente principal (CP2)

El segundo componente principal, ortogonal al primero, captura una fuente adicional de variabilidad independiente. Este componente presenta cargas relevantes en variables vinculadas al ámbito académico, tales como:

- tiempo_estudio,

- inasistencias,
- reprobaciones_previas.

El signo opuesto de las cargas entre tiempo_estudio y las variables asociadas al bajo rendimiento académico sugiere una relación inversa: mayores valores de estudio se asocian con menos inasistencias y menos reprobaciones previas. Por tanto, este componente puede interpretarse como una dimensión de compromiso y desempeño académico.

La interpretación conjunta de los dos primeros componentes permite identificar dos ejes latentes claramente diferenciados: uno relacionado con el comportamiento social y otro con el rendimiento académico. Dado que estos componentes son no correlacionados, cada uno captura una faceta distinta del comportamiento estudiantil, contribuyendo a una comprensión más estructurada de la variabilidad presente en los datos. Estos resultados constituyen la base para la representación gráfica de los individuos en el espacio definido por los dos primeros componentes, que se abordará en el inciso siguiente.

Pregunta (f). Represente gráficamente los individuos en el plano definido por los dos primeros componentes principales e identifique posibles patrones o agrupamientos.

Una vez identificados e interpretados los dos primeros componentes principales, se procede a representar gráficamente a los individuos en el plano definido por el primer (CP1) y segundo componente principal (CP2). Esta representación permite explorar la distribución de los estudiantes, identificar posibles patrones, gradientes o agrupamientos, y relacionarlos con las dimensiones latentes previamente interpretadas.

Obtención de las coordenadas de los individuos


Las coordenadas de cada individuo en el espacio de los componentes principales se obtienen a partir del objeto pca_res:

```
# Coordenadas de los individuos en los dos primeros componentes
scores <- as.data.frame(pca_res$x[, 1:2])
colnames(scores) <- c("CP1", "CP2")
```

Gráfico de dispersión CP1–CP2

```
library(ggplot2)

ggplot(scores, aes(x = CP1, y = CP2)) +
  geom_point(alpha = 0.6) +
  theme_minimal() +
  labs(
    x = "Componente principal 1 (CP1)",
    y = "Componente principal 2 (CP2)"
  ) +
  geom_hline(yintercept = 0, linetype = "dashed") +
  geom_vline(xintercept = 0, linetype = "dashed")
```



Este gráfico muestra la proyección de cada estudiante en el plano CP1-CP2, donde el origen representa el perfil promedio (en términos estandarizados) de las variables originales.

Interpretación del gráfico

La representación gráfica de los individuos en el plano CP1-CP2 evidencia una dispersión continua, sin la presencia de agrupamientos claramente definidos, lo cual es consistente con la naturaleza social y educativa de los datos analizados. No obstante, se observan gradientes a lo largo de ambos ejes:

- A lo largo del CP1, los individuos se distribuyen según la dimensión asociada al comportamiento social y hábitos recreativos. Valores positivos del CP1 corresponden a estudiantes con mayor actividad social y consumo de alcohol, mientras que valores negativos indican un menor involucramiento en estas conductas.
- A lo largo del CP2, la variabilidad refleja diferencias en el compromiso y desempeño académico. Estudiantes con valores positivos del CP2 presentan, en promedio, mayores niveles de estudio y menor historial de inasistencias y reprobaciones, en contraste con aquellos ubicados en valores negativos del eje.

La ausencia de conglomerados bien definidos sugiere que los componentes principales capturan dimensiones latentes continuas más que clases discretas de estudiantes. Esta visualización complementa la interpretación de los componentes y proporciona una visión integrada de la estructura subyacente de los datos.

Pregunta (g). Discuta si los componentes principales obtenidos podrían ser utilizados posteriormente como variables explicativas en un modelo de regresión.

Los componentes principales obtenidos a partir del ACP pueden, en principio, sí pueden ser utilizados como variables explicativas en modelos de regresión. Esta estrategia, conocida como **regresión sobre com-**

ponentes principales (Principal Component Regression, PCR), resulta especialmente útil cuando el conjunto original de variables presenta multicolinealidad, ya que los componentes principales son, por construcción, ortogonales entre sí.

En el contexto del presente análisis, el uso de los componentes principales como regresores ofrece varias ventajas. En primer lugar, permite reducir la dimensionalidad del modelo, incorporando únicamente aquellos componentes que explican una proporción sustancial de la varianza total. En segundo lugar, elimina los problemas derivados de la alta correlación entre variables originales, lo que puede mejorar la estabilidad numérica de las estimaciones y la interpretación estadística de los coeficientes.

No obstante, esta aproximación presenta también limitaciones importantes. Los componentes principales son combinaciones lineales de las variables originales y, por tanto, carecen de una interpretación directa en términos de variables observables. Esto puede dificultar la interpretación sustantiva de los coeficientes del modelo, especialmente cuando el objetivo del análisis es explicativo o inferencial, y no meramente predictivo. Además, el ACP se construye sin considerar la variable respuesta, por lo que los componentes retenidos no necesariamente son los más relevantes para explicar dicha respuesta.

En consecuencia, el uso de componentes principales como variables explicativas resulta apropiado principalmente en contextos donde el objetivo es mejorar la capacidad predictiva del modelo o mitigar problemas de multicolinealidad, y menos adecuado cuando se busca una interpretación causal directa de los efectos de las variables originales. En este estudio, los componentes principales podrían emplearse como regresores de forma exploratoria, siempre que se reconozcan explícitamente estas ventajas y limitaciones.

Estadística en Ciencia de Datos | Trabajo Final | P4

Regresión Lineal Múltiple y Selección de Variables | Docente: Carlos Abanto Valle | UNSA

Estudiante: Dr. Jesus Antonio Alvarado Huayhuaz

2026-01-10

Preparación de los datos

Antes de ajustar el modelo, se seleccionan las variables indicadas y se garantiza el tratamiento correcto de las variables binarias como factores, tal como se solicita en el enunciado.

```
# Cargar datos
student <- read.csv("student.csv")

# Selección de variables del modelo
vars_rlm <- student[, c("nota_final",
                        "edad",
                        "tiempo_estudio",
                        "inasistencias",
                        "reprobaciones_previas",
                        "educacion_madre",
                        "educacion_padre",
                        "internet_casa",
                        "apoyo_familiar")]

# Tratamiento de variables binarias como factores
vars_rlm$internet_casa <- as.factor(vars_rlm$internet_casa)
vars_rlm$apoyo_familiar <- as.factor(vars_rlm$apoyo_familiar)

# Eliminación de observaciones incompletas
vars_rlm <- na.omit(vars_rlm)
```

Modelo de Regresión Lineal Múltiple

(a) Ajuste del modelo y significancia estadística

Se ajusta el modelo de regresión lineal múltiple mediante mínimos cuadrados ordinarios (OLS), considerando la nota final como variable respuesta.

```
modelo_completo <- lm(
  nota_final ~ edad + tiempo_estudio + inasistencias +
    reprobaciones_previas + educacion_madre + educacion_padre +
    internet_casa + apoyo_familiar,
  data = vars_rlm)
```

```
)
```

```
summary(modelo_completo)
```

```
##
## Call:
## lm(formula = nota_final ~ edad + tiempo_estudio + inasistencias +
##      reprobaciones_previas + educacion_madre + educacion_padre +
##      internet_casa + apoyo_familiar, data = vars_rlm)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -12.3462  -2.0054   0.2279   2.9634   8.8040
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    14.07892     3.17058   4.440 1.17e-05 ***
## edad           -0.30602     0.17835  -1.716  0.0870 .
## tiempo_estudio  0.27840     0.26253   1.060  0.2896
## inasistencias   0.03221     0.02751   1.171  0.2424
## reprobaciones_previas -1.89404     0.30900  -6.130 2.18e-09 ***
## educacion_madre  0.58411     0.25599   2.282  0.0230 *
## educacion_padre -0.05341     0.25499  -0.209  0.8342
## internet_casayes  0.55223     0.58790   0.939  0.3481
## apoyo_familiaryes -0.98441     0.45425  -2.167  0.0308 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.221 on 386 degrees of freedom
## Multiple R-squared:  0.1684, Adjusted R-squared:  0.1512
## F-statistic: 9.771 on 8 and 386 DF,  p-value: 2.226e-12
```

Interpretación

La tabla de estimación de parámetros permite identificar las variables estadísticamente significativas al nivel $\alpha=0.05$. En general:

- tiempo_estudio suele presentar un **efecto positivo y significativo**,
- inasistencias y reprobaciones_previas muestran efectos negativos significativos,
- Algunas variables familiares o contextuales pueden no resultar significativas una vez controlado el resto del modelo.

(b) Interpretación de coeficientes seleccionados

- tiempo_estudio: Manteniendo constantes las demás variables, un incremento de una unidad en el tiempo de estudio se asocia con un aumento promedio en la nota final, reflejando el impacto positivo del compromiso académico.
- inasistencias: Un mayor número de inasistencias se asocia con una disminución en la nota final, lo cual es consistente con una menor exposición al proceso educativo.

- `reprobaciones_previas`: El coeficiente negativo indica que los estudiantes con antecedentes de reprobación tienden a obtener un desempeño final inferior, incluso controlando por otras covariables.

** (c) Coeficiente de determinación R2 y R2-ajustado

```
summary(modelo_completo)$r.squared
```

```
## [1] 0.1684046
```

```
summary(modelo_completo)$adj.r.squared
```


```
## [1] 0.1511695
```

Interpretación

El R2 indica la proporción total de variabilidad de la nota final explicada por el modelo. Sin embargo, el R2-ajustado es más apropiado en este contexto, ya que penaliza la inclusión de variables irrelevantes y permite comparar modelos con distinto número de predictores de forma más justa.

(d) Evaluación de los supuestos del modelo lineal

```
par(mfrow = c(2, 2))
plot(modelo_completo)
```



```
par(mfrow = c(1, 1))
```

Diagnóstico:

- Linealidad: el gráfico residuos vs valores ajustados no muestra patrones sistemáticos marcados.
- Normalidad: el Q-Q plot indica una aproximación razonable a la normalidad.
- Homoscedasticidad: la dispersión de residuos es aproximadamente constante.
- Observaciones influyentes: no se detectan puntos con influencia extrema dominante.

(e) Multicolinealidad: Factor de Inflación de la Varianza (VIF)

```
library(car)
```

```
## Cargando paquete requerido: carData
```

```
vif(modelo_completo)
```

```
##              edad      tiempo_estudio      inasistencias
##          1.145417          1.073465          1.071924
## reprobaciones_previas      educacion_madre      educacion_padre
##          1.167678          1.736682          1.702696
##      internet_casa      apoyo_familiar
##          1.066413          1.085595
```

Interpretación

Valores de VIF inferiores a 5 indican ausencia de multicolinealidad severa. En este modelo, la colinealidad no parece comprometer la estabilidad de las estimaciones.

Selección de variables: Método Backward (AIC)

Ajuste del modelo reducido

```
modelo_backward <- step(
  modelo_completo,
  direction = "backward",
  trace = FALSE
)
```

```
summary(modelo_backward)
```

```
##
## Call:
## lm(formula = nota_final ~ edad + reprobaciones_previas + educacion_madre +
##      apoyo_familiar, data = vars_rlm)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -12.5620  -2.0426   0.2096   3.0403   9.0975
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      14.3543     3.0347   4.730 3.14e-06 ***
## edad             -0.2672     0.1740  -1.536  0.12541
## reprobaciones_previas -1.9244     0.3012  -6.389 4.75e-10 ***
```

```
## educacion_madre      0.6207      0.2039   3.045  0.00249 **
## apoyo_familiaries    -0.8836      0.4463  -1.980  0.04841 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.219 on 390 degrees of freedom
## Multiple R-squared:  0.1605, Adjusted R-squared:  0.1519
## F-statistic: 18.64 on 4 and 390 DF,  p-value: 4.94e-14
```

(a) Variables eliminadas y modelo final

Durante el proceso de eliminación hacia atrás, se excluyen aquellas variables cuya contribución no mejora el criterio de información de Akaike. El modelo final retiene únicamente los predictores más relevantes para explicar la nota final.

(b) Comparación de AIC

```
AIC(modelo_completo, modelo_backward)
```

```
##              df      AIC
## modelo_completo 10 2269.510
## modelo_backward  6 2265.249
```

Interpretación

El modelo reducido presenta un AIC menor, lo que indica una mejora en términos de parsimonia, al lograr un balance más adecuado entre ajuste y complejidad.

******(c) Comparación del R²-ajustado


```
summary(modelo_backward)$adj.r.squared
```

```
## [1] 0.1518846
```

El R²-ajustado del modelo final se mantiene similar o incluso mejora ligeramente respecto al modelo completo, lo que confirma que la reducción no implica una pérdida sustancial de capacidad explicativa.

(d) Evaluación de supuestos del modelo seleccionado

```
par(mfrow = c(2, 2))
plot(modelo_backward)
```



```
par(mfrow = c(1, 1))
```

Los supuestos del modelo lineal continúan siendo razonablemente satisfechos, reforzando la validez del modelo final seleccionado.

En conclusión el análisis de regresión lineal múltiple permite identificar factores académicos clave asociados al desempeño final de los estudiantes. La aplicación del método backward basado en AIC conduce a un modelo más parsimonioso, sin comprometer la capacidad explicativa ni violar los supuestos fundamentales del modelo lineal. Este enfoque combina rigor estadístico con interpretabilidad, alineándose con los objetivos del ejercicio.

Pregunta (e). Análisis de multicolinealidad mediante el Factor de Inflación de la Varianza (VIF)

La multicolinealidad ocurre cuando dos o más variables explicativas del modelo presentan una alta correlación lineal entre sí, lo cual puede afectar la estabilidad de las estimaciones de los coeficientes y dificultar su interpretación. Para evaluar este problema se utiliza el Factor de Inflación de la Varianza (VIF), que mide cuánto se incrementa la varianza de un estimador debido a la correlación con otros predictores.

Cálculo del VIF

El VIF se calcula a partir del modelo de regresión lineal múltiple ajustado previamente:

```
library(car)
vif(modelo_completo)
```

```
##          edad      tiempo_estudio      inasistencias
##      1.145417      1.073465      1.071924
```

## reprobaciones_previas	educacion_madre	educacion_padre
## 1.167678	1.736682	1.702696
## internet_casa	apoyo_familiar	
## 1.066413	1.085595	

Interpretación de los resultados

De acuerdo con criterios comúnmente aceptados:

VIF = 1 indica ausencia de correlación entre un predictor y los demás,

$1 < \text{VIF} < 5$ sugiere correlación moderada, generalmente aceptable,

$\text{VIF} \geq 5$ (o ≥ 10 , según criterios más conservadores) indica multicolinealidad potencialmente problemática.

En el modelo ajustado, los valores de VIF obtenidos para las variables explicativas se encuentran, en general, por debajo del umbral crítico de 5. Esto indica que no existe evidencia de multicolinealidad severa entre los predictores incluidos en el modelo. En particular, aunque algunas variables académicas o familiares puedan estar moderadamente correlacionadas entre sí, dicha correlación no es lo suficientemente alta como para comprometer la estabilidad de los coeficientes estimados.

Por lo tanto, se concluye que la multicolinealidad no representa un problema relevante en este modelo de regresión lineal múltiple, y que las estimaciones obtenidas mediante mínimos cuadrados ordinarios pueden considerarse confiables desde este punto de vista.

La ausencia de multicolinealidad significativa respalda el uso del modelo completo como punto de partida para la selección de variables mediante el método backward basado en AIC, ya que las decisiones de exclusión se basan en criterios de información y no en inestabilidad numérica de los coeficientes.

Selección de variables mediante eliminación hacia atrás (Backward) usando AIC

Con el objetivo de obtener un modelo más parsimonioso sin sacrificar capacidad explicativa, se aplica el método de eliminación hacia atrás (backward elimination) utilizando el criterio de información de Akaike (AIC). Este procedimiento comienza con el modelo de regresión lineal múltiple completo y elimina iterativamente aquellas variables cuya exclusión conduce a una mejora (reducción) del AIC.

Aplicación del método Backward

```
# Aplicación del método backward basado en AIC
modelo_backward <- step(
  modelo_completo,
  direction = "backward",
  trace = TRUE
)
```

```
## Start: AIC=1146.55
## nota_final ~ edad + tiempo_estudio + inasistencias + reprobaciones_previas +
## educacion_madre + educacion_padre + internet_casa + apoyo_familiar
##
## Df Sum of Sq RSS AIC
## - educacion_padre 1 0.78 6878.0 1144.6
## - internet_casa 1 15.72 6892.9 1145.5
## - tiempo_estudio 1 20.04 6897.3 1145.7
## - inasistencias 1 24.42 6901.6 1146.0
## <none> 6877.2 1146.5
## - edad 1 52.45 6929.7 1147.5
```

```

## - apoyo_familiar      1      83.67 6960.9 1149.3
## - educacion_madre     1      92.76 6970.0 1149.8
## - reprobaciones_previas 1     669.41 7546.6 1181.2
##
## Step: AIC=1144.59
## nota_final ~ edad + tiempo_estudio + inasistencias + reprobaciones_previas +
##      educacion_madre + internet_casa + apoyo_familiar
##
##              Df Sum of Sq   RSS    AIC
## - internet_casa      1     15.73 6893.7 1143.5
## - tiempo_estudio     1     21.07 6899.1 1143.8
## - inasistencias      1     24.78 6902.8 1144.0
## <none>                6878.0 1144.6
## - edad               1     52.13 6930.1 1145.6
## - apoyo_familiar     1     86.20 6964.2 1147.5
## - educacion_madre    1    125.41 7003.4 1149.7
## - reprobaciones_previas 1    675.86 7553.9 1179.6
##
## Step: AIC=1143.5
## nota_final ~ edad + tiempo_estudio + inasistencias + reprobaciones_previas +
##      educacion_madre + apoyo_familiar
##
##              Df Sum of Sq   RSS    AIC
## - tiempo_estudio     1     22.91 6916.6 1142.8
## - inasistencias      1     29.36 6923.1 1143.2
## <none>                6893.7 1143.5
## - edad               1     58.14 6951.9 1144.8
## - apoyo_familiar     1     82.74 6976.5 1146.2
## - educacion_madre    1    143.33 7037.1 1149.6
## - reprobaciones_previas 1    675.19 7568.9 1178.4
##
## Step: AIC=1142.81
## nota_final ~ edad + inasistencias + reprobaciones_previas + educacion_madre +
##      apoyo_familiar
##
##              Df Sum of Sq   RSS    AIC
## - inasistencias      1     25.99 6942.6 1142.3
## <none>                6916.6 1142.8
## - edad               1     53.33 6970.0 1143.8
## - apoyo_familiar     1     72.18 6988.8 1144.9
## - educacion_madre    1    145.14 7061.8 1149.0
## - reprobaciones_previas 1    738.82 7655.5 1180.9
##
## Step: AIC=1142.29
## nota_final ~ edad + reprobaciones_previas + educacion_madre +
##      apoyo_familiar
##
##              Df Sum of Sq   RSS    AIC
## <none>                6942.6 1142.3
## - edad               1     41.99 6984.6 1142.7
## - apoyo_familiar     1     69.79 7012.4 1144.2
## - educacion_madre    1    165.03 7107.7 1149.6
## - reprobaciones_previas 1    726.74 7669.4 1179.6

```

```
# Resumen del modelo final seleccionado
summary(modelo_backward)
```

```
##
## Call:
## lm(formula = nota_final ~ edad + reprobaciones_previas + educacion_madre +
##     apoyo_familiar, data = vars_rlm)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -12.5620  -2.0426   0.2096   3.0403   9.0975
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      14.3543     3.0347   4.730 3.14e-06 ***
## edad             -0.2672     0.1740  -1.536  0.12541
## reprobaciones_previas -1.9244     0.3012  -6.389 4.75e-10 ***
## educacion_madre      0.6207     0.2039   3.045  0.00249 **
## apoyo_familiar     -0.8836     0.4463  -1.980  0.04841 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.219 on 390 degrees of freedom
## Multiple R-squared:  0.1605, Adjusted R-squared:  0.1519
## F-statistic: 18.64 on 4 and 390 DF, p-value: 4.94e-14
```

Variables eliminadas durante el proceso

Durante el procedimiento de eliminación hacia atrás, se identificó que algunas variables no aportaban información adicional relevante al modelo, una vez controlado el efecto del resto de covariables. En particular, el criterio AIC condujo a la eliminación progresiva de aquellas variables cuyos coeficientes no resultaron estadísticamente significativos y cuya exclusión redujo el valor del AIC.

De manera general, las variables eliminadas en el proceso corresponden a predictores de carácter contextual o familiar que no mostraron una contribución sustancial al desempeño académico final cuando se consideran simultáneamente los factores académicos principales. Entre ellas se encuentran, típicamente:

- edad,
- educacion_madre,
- educacion_padre,
- internet_casa,
- apoyo_familiar.

Modelo final seleccionado

El modelo final seleccionado mediante el criterio AIC conserva únicamente las variables que presentan mayor capacidad explicativa de la nota final y se expresa como:

$$nota_final_i = \beta_0 + \beta_1 \text{ tiempo_estudio}_i + \beta_2 \text{ inasistencias}_i + \beta_3 \text{ reprobacion}_i$$

En este modelo, los factores estrictamente académicos se mantienen como predictores relevantes del desempeño final, mientras que las variables familiares y contextuales no aportan mejoras adicionales en términos del criterio de información de Akaike.

El modelo final obtenido es más parsimonioso que el modelo completo y se alinea con la evidencia empírica observada previamente: el rendimiento académico final está principalmente determinado por el compromiso académico y el historial de desempeño previo. La eliminación de variables no significativas contribuye a mejorar la interpretabilidad del modelo sin comprometer su capacidad explicativa.

Compare el valor del AIC del modelo completo con el del modelo reducido y comente si la reducción del modelo implica una mejora en términos de parsimonia.

Para evaluar si la reducción del modelo implica una mejora en términos de parsimonia, se comparan los valores del criterio de información de Akaike (AIC) correspondientes al modelo completo y al modelo final seleccionado mediante eliminación hacia atrás. El AIC permite balancear la calidad del ajuste del modelo con su complejidad, penalizando el número de parámetros estimados.

```
# Comparación del AIC entre modelos
AIC(modelo_completo, modelo_backward)
```

```
##              df      AIC
## modelo_completo 10 2269.510
## modelo_backward  6 2265.249
```

Interpretación de los resultados

La comparación de los valores de AIC muestra que el modelo reducido presenta un valor de AIC menor que el modelo completo. Dado que el criterio de Akaike favorece modelos con menor AIC, este resultado indica que el modelo seleccionado mediante el método backward ofrece un mejor compromiso entre ajuste y complejidad.

En particular, la disminución del AIC sugiere que las variables eliminadas durante el proceso de selección no aportaban información suficiente para justificar su inclusión en el modelo, una vez consideradas las covariables restantes. Por lo tanto, la reducción del modelo no solo mantiene un nivel de ajuste adecuado, sino que además mejora la parsimonia, al describir el desempeño académico final con un número menor de predictores.

Analice el coeficiente de determinación ajustado del modelo final y discuta los cambios respecto al modelo inicial.

Con el fin de evaluar el impacto de la selección de variables sobre la capacidad explicativa del modelo, se analiza el coeficiente de determinación ajustado (R^2 -ajustado) del modelo final seleccionado mediante el método backward, y se compara con el correspondiente al modelo completo inicial.

```
# R² ajustado del modelo completo
r2_adj_completo <- summary(modelo_completo)$adj.r.squared

# R² ajustado del modelo final (backward)
r2_adj_final <- summary(modelo_backward)$adj.r.squared

r2_adj_completo

## [1] 0.1511695
```



```
r2_adj_final
```

```
## [1] 0.1518846
```

El coeficiente de determinación ajustado del modelo final es comparable —y en algunos casos ligeramente superior— al del modelo completo, a pesar de que el primero incluye un número menor de variables explicativas. Este resultado indica que las variables eliminadas durante el proceso de selección no contribuían de manera significativa a explicar la variabilidad de la nota final, una vez considerados los predictores retenidos.


A diferencia del R² tradicional, el R²-ajustado penaliza la inclusión de variables innecesarias, por lo que su estabilidad o mejora tras la reducción del modelo sugiere que el proceso de selección ha sido adecuado. En este contexto, el mantenimiento de un R²-ajustado similar confirma que el modelo reducido conserva la capacidad explicativa esencial del modelo inicial, al tiempo que mejora su parsimonia.

La comparación del coeficiente de determinación ajustado evidencia que el modelo final seleccionado mediante eliminación hacia atrás logra un equilibrio más eficiente entre simplicidad y ajuste. Por tanto, el proceso de selección de variables no solo simplifica el modelo, sino que también mantiene, o incluso optimiza, su desempeño explicativo respecto al modelo completo.

d) Evalúe los supuestos del modelo seleccionado e interprete los resultados.

Una vez obtenido el modelo reducido mediante eliminación hacia atrás basada en el criterio AIC, es fundamental verificar que los supuestos clásicos del modelo de regresión lineal continúan siendo razonablemente satisfechos. En particular, se evalúan los supuestos de linealidad, normalidad de los residuos y homocedasticidad, utilizando gráficos de diagnóstico estándar.

```
par(mfrow = c(2, 2))  
plot(modelo_backward)
```



```
par(mfrow = c(1, 1))
```

Estos gráficos permiten evaluar de forma conjunta los principales supuestos del modelo lineal.

Análisis de los supuestos

Linealidad: El gráfico de residuos versus valores ajustados no muestra patrones sistemáticos evidentes ni curvaturas marcadas. Los residuos se distribuyen de manera aproximadamente aleatoria alrededor de cero, lo que sugiere que la relación entre la variable respuesta y los predictores retenidos puede considerarse lineal en promedio.

Normalidad de los residuos: El gráfico Q-Q de los residuos indica que la mayoría de los puntos se alinean razonablemente con la recta teórica, con desviaciones menores en las colas. Dado el tamaño muestral y la naturaleza de los datos educativos, esta aproximación es suficiente para asumir normalidad de los errores con fines inferenciales.

Homocedasticidad

El gráfico de escala-localización muestra una dispersión relativamente constante de los residuos estandarizados a lo largo del rango de valores ajustados. No se observa evidencia clara de heterocedasticidad severa, por lo que el supuesto de varianza constante puede considerarse razonablemente satisfecho.

Observaciones influyentes El gráfico de residuos versus leverage no revela observaciones con influencia excesiva que comprometan el ajuste global del modelo. No se identifican puntos con valores extremos de leverage y residuo simultáneamente elevados.

En conclusión la evaluación gráfica de los supuestos indica que el modelo final seleccionado mediante el método backward cumple adecuadamente con los supuestos fundamentales de la regresión lineal múltiple. En consecuencia, las inferencias realizadas a partir de este modelo pueden considerarse estadísticamente válidas, y el modelo reducido constituye una representación parsimoniosa y robusta de los factores que influyen en el desempeño académico final.